

AI算力池化的五大场景揭秘

CSDN 2022-03-22 17:38



导读

Jim哥2007年加入VMware中国，经历了整个企业级市场从服务器虚拟化、私有云、公有云、容器云、混合云到云原生蓬勃发展的过程，也见证了从软件定义的计算存储、网络到软件定义一切的概念延伸。2021年Jim哥加入趋动科技，投身到软件定义AI算力的这一波浪潮中。本文不打算说概念和逻辑，而是尝试通过五大实际客户场景来看看如何通过软件定义的方法对AI算力做优化，解决痛点问题，供各位老板们参考。

GPU服务器相对CPU服务器来说是非常昂贵的，大约是美金和人民币汇率的差距（以8卡GPU服务器为例），而且在芯片紧缺的年代，GPU到货周期还比较长！面对资源昂贵、算力又是AI的发动机、AI业务又必须开展之间的矛盾，如何更好的利用和管理GPU资源就变得尤其关键。下面一起来看看这五大典型场景。


◆◆◆◆

场景一：AI开发测试

◆◆◆◆

大多数的客户采取的是为一个开发者分配一块或几块GPU卡的方式来满足开发调试的需求。这种情况下存在什么问题？卡和人绑定，卡分配之后，存在着较大的闲置，开发人员70%以上的时间都在读论文、写代码，只有不到30%的时间在利用GPU资源进行运算调试。利用软件定义GPU的技术，把卡和人解绑，当有任务调用GPU资源的时候才真正被占用，任务结束，资源释放，回到资源池。

下图是一个JupyterLab的开发场景，VSCode server/PyCharm的模式与这个类似，在实际的客户案例里，使用软件定义的GPU之后，资源能缩减至25%左右！50个人的开发团队，16张卡搞定。



使用OrionX前：
每人分配1张或几张物理GPU卡，统计发现利用率低，浪费严重，峰值利用率仅为21.8%，平均利用率低于10%。

使用OrionX后：
对GPU卡资源进行池化后共享，每人按需动态进行GPU挂载和释放，卡数量减少70%以上。

图1: OrionX在AI开发中动态调用卡资源示例

◆◆◆◆

场景二：生产环境的AI推理业务

◆◆◆◆

通过调查，绝大多数的用户业务为了保证业务的隔离性，不受其它AI业务的干扰，保障服务的SLA，都是运行在独立的GPU卡上。在这种情况下，GPU卡的算力和显存使用往往不到20%，这样造成了大量的资源浪费——近80%的算力和显存其实是被白白消耗，而且还有与之

相关的**电费，运维**费用。通过软件定义的方式，提供**细颗粒度的GPU资源复用单卡**，保障业务运行的隔离性，可靠性和性能。大部分采取**趋动科技池化方案**上线生产业务的客户，可获得**3倍以上的提升收益**。




图2: OrionX在生产环境中的单卡多业务复用示例

场景三：昼夜复用

在前两种场景中，不管是AI开发，还是AI线上推理，基本上都是白天比较繁忙，卡利用率相对较高。到了**晚间**，卡资源基本就处于**闲置**状态，白白浪费！在一个证券客户那里，我们尝试着利用OrionX解决这个问题。通过软件定义的方式，**弹性的分配和调度资源**，晚上利用卡资源进行训练任务的运算，大大提升了闲时(夜间)资源利用率。

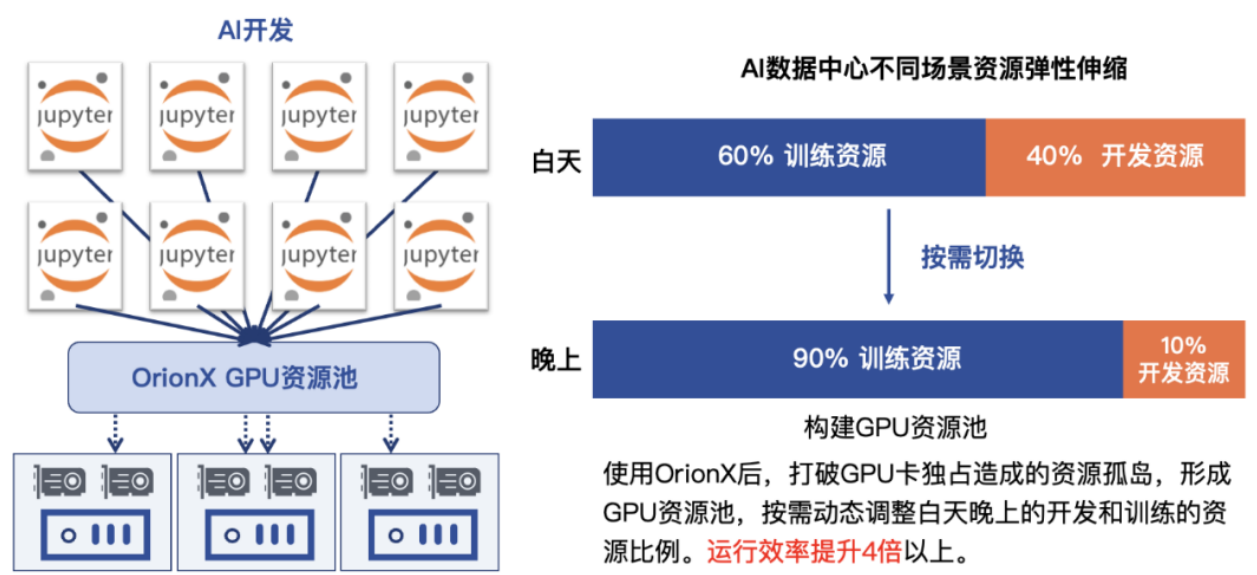


图3: OrionX按需对卡进行昼夜复用示例

场景四：CPU和GPU的资源配比

大多数的AI开发涉及到从数据准备，预处理，模型训练，调参，部署模型，线上推理，持续监控，数据收集，迭代优化的过程。在整个业务流程中，有些工作是需要大量CPU，不需要GPU资源的，在CPU运算的时候，其实GPU是闲置的；在一个自动驾驶客户那里，我们看到的仿真场景下，一个8卡的GPU的服务器，在**CPU耗尽（占用100%）的情况下，最多只能使用到其中的3块GPU卡**，剩下的5张GPU卡处在

闲置状态，无法被充分利用。同样的道理，也可能存在GPU卡在大量占用，CPU资源被闲置的情况。通过利用软件定义的AI算力，将CPU和GPU解耦，一举解决CPU/GPU资源不匹配的问题。

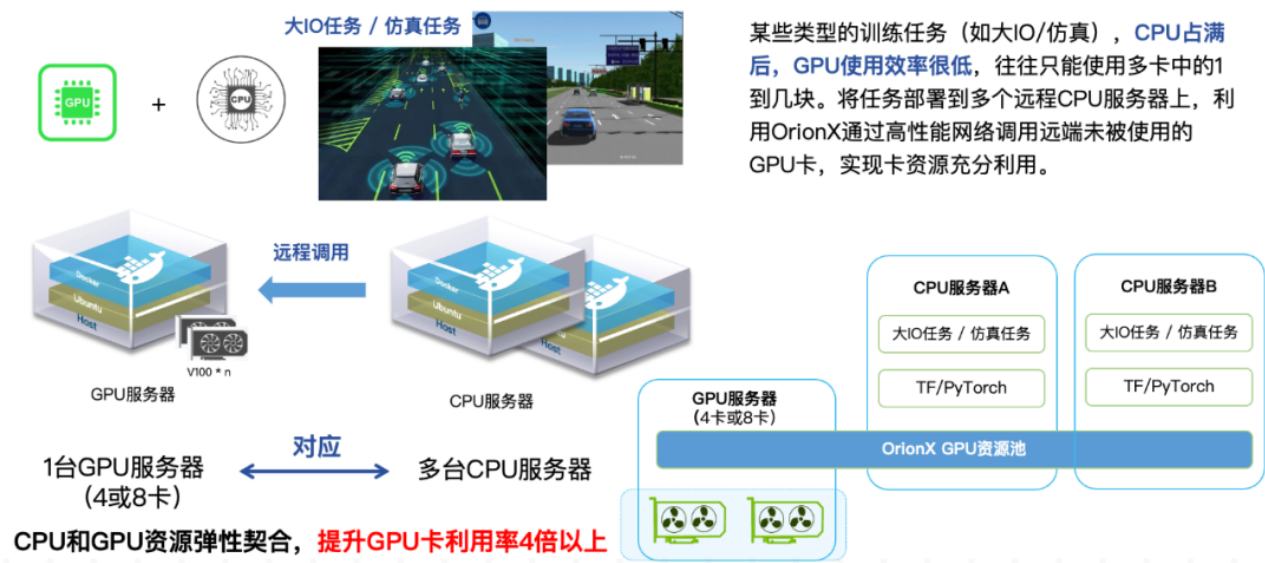


图4: OrionX优化CPU和GPU资源配比示例

场景五：显存超分

这是我们在一个金融客户那里遇到的真实案例，我们看到一个大数据AI分析流程，运行在1张16G显存的T4卡上，其需要占用大约20%的算力，12Gb的显存，服务常驻用在处理保单的识别和分析。在这种情况下，该卡剩余的80%算力，4Gb（25%）的显存处在闲置状态，无法被使用，成了资源碎片。

要想利用资源碎片，一种思路是找到适合碎片的算力任务也运行到这张卡（未必好找）。运用软件定义的虚拟显存的技术，使用部分内存来补足显存，让两个任务同时运行在这张卡上。资源不变，通量达到1.8倍！

你可能还会想到，如果在跑一个训练任务的时候，模型所需的物理显存不够，是不是也可以用内存来补足加载？是的。可以加载运行，但是要付出一定的性能损耗。此方案在必须改模型或要采购大显存物理卡之外，又提供了一种可能的选择。



图5: OrionX显存超分提升资源利用率示例

以上利用软件定义GPU的方法来优化AI算力的五大场景，只是我们看到的冰山一角。软件定义GPU所能带来的业务价值，还有待于企业客户在各个领域的不停探索。

除此之外，不得不提一下此项技术额外的**Bonus，降低碳排放，保护地球家园！**




图6: OrionX关键效能指标收益对比示例

最后，做个小结。软件定义的核心是通过软件定义的方法，将各种硬件（CPU、内存、磁盘、I/O等）变成**可以动态管理的“资源池”**，从而提升资源的利用率，简化系统管理，实现资源整合，让IT对业务的变化更具适应力。

软件定义的AI算力，一方面可以把一颗物理加速芯片（GPU或ASIC）变成几个或几十个**互相隔离的小的计算单元**，也可以把分布在不同物理服务器上的加速芯片**聚合**给一个操作系统（物理机/虚拟机）或容器，完成分布式任务。此外，没有加速芯片（GPU或ASIC）的CPU服务器也可以**调用远程服务器上的加速卡**(GPU或ASIC)完成AI运算，实现CPU与GPU设备的解耦。软件定义实质是通过软件的方法**提供更有弹性的硬件**。

喜欢此内容的人还喜欢

687亿美元！动视CEO丑闻曝光3天，微软立即开始重金收购谈判

新智元

咖啡、小面、低度酒之后，新消费下一个风口是吃鱼？

Tech星球

i-Family | 全球头部科技鞋履品牌集团「Miracle Miles」获1亿美金A轮融资，IDG资本参与联合领投

IDG资本