

CSDN 2022-03-22 17:38





## 导读 =

Jim哥2007年加入VMware中国,经历了整个企业级市场从服务器虚拟化、私有云、公有云、容器云、混合云到云原生蓬勃发展的过程,也见证了从软件定义的计算存储、网络到软件定义一切的概念延伸。2021年Jim哥加入趋动科技,投身到软件定义AI算力的这一波浪潮中。本文不打算说概念和逻辑,而是尝试**通过五大实际客户场景来看看如何通过软件定义的方法来对AI算力做优化**,解决痛点问题,供各位老板们参考。

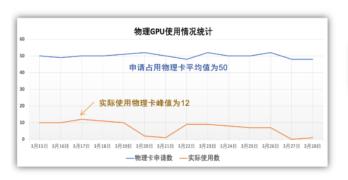
GPU服务器相对CPU服务器来说是非常昂贵的,大约是美金和人民币汇率的差距(以8卡GPU服务器为例),而且在芯片紧缺的年代,GPU到货周期还比较长!面对资源昂贵、算力又是AI的发动机、AI业务又必须开展之间的矛盾,如何更好的利用和管理GPU资源就变得尤其关键。下面一起来看看这**五大典型场景**。

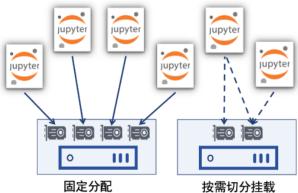
## 场景一: AI开发测试

\* \* \* \*

大多数的客户采取的是为一个开发者分配一块或几块GPU卡的方式来满足开发调试的需求。这种情况下存在什么问题?卡和人绑定,卡分配之后,存在着**较大的闲置**,开发人员70%以上的时间都在读论文、写代码,只有不到30%的时间在利用GPU资源进行运算调试。利用软件定义GPU的技术,把卡和人解绑,当有任务调用GPU资源的时候才真正被占用,任务结束,资源释放,回到资源池。

下图是一个JupyterLab的开发场景,VSCode server/PyCharm的模式与这个类似,在实际的客户案例里,使用软件定义的GPU之后,**资** 源能缩减至25%左右! 50个人的开发团队,16张卡搞定。





## 使用OrionX前:

每人分配1张或几张物理GPU卡,统计发现利用率低,浪费严重,**峰值**利用率仅为21.8%,平均利用率低于10%。

## 使用OrionX后:

对GPU卡资源进行池化后共享,每人按需动态进行GPU挂载和释放,卡数量减少70%以上。

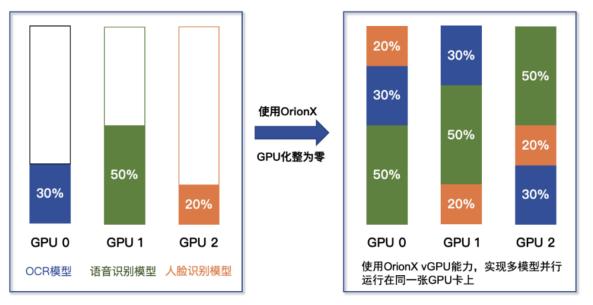
图1: OrionX在AI开发中动态调用卡资源示例

场景二: 生产环境的AI推理业务

\* \* \* \*

通过调查,绝大多数的用户业务为了保证业务的隔离性,不受其它AI业务的干扰,保障服务的SLA,都<mark>是运行在独立的GPU卡上</mark>。在这种情况下,GPU卡的算力和显存使用往往不到20%,这样造成了大量的资源浪费——近80%的算力和显存其实是被白白消耗,而且还有与之

相关的**电费,运维**费用。通过软件定义的方式,提供**细颗粒度的GPU资源复用单卡**,保障业务运行的隔离性,可靠性和性能。大部分采取 趋动科技池化方案上线生产业务的客户,可获得**3倍以上的提升收益**。



使用OrionX前:不同推理模型运行在独立的GPU卡上,每一块GPU卡都没有得到充分使用,造成资源浪费。

使用OrionX后:不同AI业务推理模型运行在相对应的虚拟GPU上,实现GPU整体利用率提升3倍以上,节省卡资源。

图2: OrionX在生产环境中的单卡多业务复用示例

场景三:昼夜复用

在前两种场景中,不管是AI开发,还是AI线上推理,基本上都是白天比较繁忙,卡利用率相对较高。到了**晚间**,卡资源基本就处于闲置状态,白白浪费!在一个证券客户那里,我们尝试着利用OrionX解决这个问题。通过软件定义的方式,**弹性的分配和调度资源**,晚上利用卡资源进行训练任务的运算,大大提升了闲时(夜间)资源利用率。

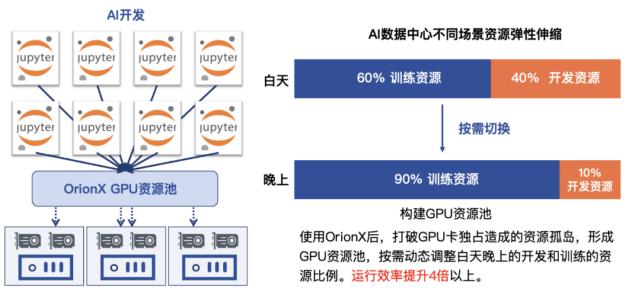


图3: OrionX按需对卡进行昼夜复用示例

场景四: CPU和GPU的资源配比

大多数的AI开发涉及到从数据准备,预处理,模型训练,调参,部署模型,线上推理,持续监控,数据收集,迭代优化的过程。在整个业务流程中,有些工作是需要大量CPU,不需要GPU资源的,在CPU运算的时候,其实GPU是闲置的;在一个自动驾驶客户那里,我们看到在仿真场景下,一个8卡的GPU的服务器,在CPU耗尽(占用100%)的情况下,最多只能使用到其中的3块GPU卡,剩下的5张GPU卡处在

闲置状态,无法被充分利用。同样的道理,也可能存在GPU卡在大量占用,CPU资源被闲置的情况。通过利用软件定义的AI算力<mark>,将CPU和GPU解耦,一举解决CPU/GPU资源不匹配的问题。</mark>

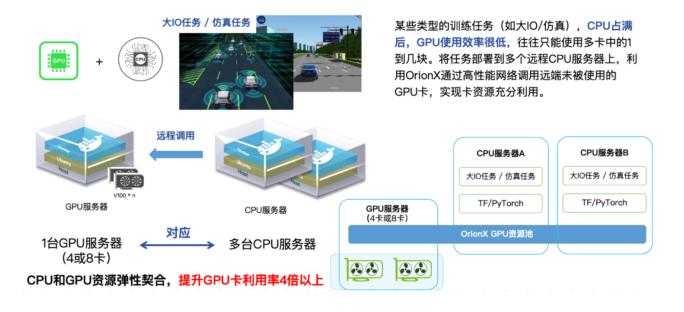


图4: OrionX优化CPU和GPU资源配比示例

. . . .

场景五: 显存超分

这是我们在一个金融客户那里遇到的真实案例,我们看到一个大数据AI分析流程,运行在1张16G显存的T4卡上,其需要占用大约20%的算力,12Gb的显存,服务常驻用在处理保单的识别和分析。在这种情况下,该卡剩余的80%算力,4Gb(25%)的显存处在闲置状态,无法被使用,成了**资源碎片。** 

要想利用资源碎片,一种思路是找到适合碎片的算力任务也运行到这张卡(未必好找)。运用软件定义的虚拟显存的技术,**使用部分内存来补足显存**,让两个任务同时运行在这张卡上。资源不变,**通量达到1.8倍!** 

你可能还会想到,如果在跑一个训练任务的时候,模型所需的物理显存不够,是不是也可以用内存来补足加载?是的。可以加载运行,但是要付出一定的性能损耗。此方案在必须改模型或要采购大显存物理卡之外,又提供了一种可能的选择。



图5: OrionX显存超分提升资源利用率示例

以上利用软件定义GPU的方法来优化AI算力的五大场景,只是我们看到的冰山一角。软件定义GPU所能带来的业务价值,还有待于企业客户在各个领域的不停探索。

除此之外,不得不提一下此项技术额外的Bonus,降低碳排放,保护地球家园!



图6: OrionX关键效能指标收益对比示例

最后,做个小结。软件定义的核心是通过软件定义的方法,将各种硬件(CPU、内存、磁盘、I/0等)变成<mark>可以动态管理的"资源池",</mark>从而提升资源的利用率,简化系统管理,实现资源整合,让IT对业务的变化更具适应力。

软件定义的AI算力,一方面可以把一颗物理加速芯片(GPU或ASIC)变成几个或几十个**互相隔离的小的计算单元**,也可以把分布在不同物理服务器上的加速芯片**聚合**给一个操作系统(物理机/虚拟机)或容器,完成分布式任务。此外,没有加速芯片(GPU或ASIC)的CPU服务器也可以**调用远程服务器上的加速卡**(GPU或ASIC)完成AI运算,实现CPU与GPU设备的解耦。软件定义实质是通过软件的方法**提供更有弹性的硬件**。

喜欢此内容的人还喜欢

687亿美元! 动视CEO丑闻曝光3天, 微软立即开始重金收购谈判

新智元

咖啡、小面、低度酒之后,新消费下一个风口是吃鱼?

Tech星球

i-Family | 全球头部科技鞋履品牌集团「Miracle Miles」获1亿美金A轮融资,IDG资本参与联合领投IDG资本